

영유아 발달 관찰 보조를 위한 행동 인식 시스템

A Video Vision Transformer



데청캠 고려대 12조

고수연 김성률 송재희 한용준 황현웅





목차

1. 주제 선정 배경
2. 분석 프로세스
3. 데이터 구축
4. 데이터 모델링
5. 최종 결과
6. 서비스 기획
7. 참고문헌

1. 주제 선정 배경¹⁾ 개념 정의

유아 발달 영역

연령별 발달 특성을 6가지 영역으로 나누어 정리한 것



아이의 행동을 기반으로
발달의 정도 파악

01 기본 생활

02 신체 운동

03 의사소통

04 사회관계

05 예술 경험


06 자연 탐구



박수를 친다.



걸어 다닌다



블럭을 2개 이상 쌓는다.




스스로 물을 마신다

* 출처: (보건복지부 고시 제2020 - 75호) 「영유아보육법」 제29조제2항,
「영유아보육법 시행규칙」 제30조에 의거한 제4차 표준보육과정

1. 주제 선정 배경²⁾ 문제 발굴


현장 인터뷰

선생님들이 의무적으로 원아의 행동을 기록하게 되어 있음.
하지만 이것으로는 부족함.



ALL
부모와 선생님 모두
또래 집단 대비
아이의 행동 발달 정도가
주요 관심사

2. 분석 프로세스



3. 데이터 구축¹⁾ 행동 선정

행동 발달 체크리스트

행동발달 체크리스트				
만 나이		연아명		
생년월일				
평가 표시		가 : 혼자 할 수 있다. 나 : 도움주면 할 수 있다. 다 : 현재 할 수 없고, 지도필요		
영역	행동특성	가	나	다
기본생활습관	건강하게 생활하기	몸이 깨끗해졌을 때 기분이 좋음을 안다.	√	
		도움을 받아 손을 씻는다.	√	
		도움을 받아 이를 닦는다.	√	
		다양한 음식을 먹어본다.		√
		도구로 음식을 먹어본다.	√	
		즐겁게 먹는다.	√	
		수면을 충분히 취하고 편안하게 쉰다.	√	
		하루일과에 편안하게 참여한다.	√	
	배변 의사를 표현한다.	√		
	안전하게 생활하기	놀잇감을 안전하게 사용한다.	√	
안전한 장소에서 놀이한다.		√		
차량 승하차 시 안전 장구를 착용한다.		√		
	위험하다고 알려주면 주의한다.	√		
평가	혼자서 배변을 할 때 옷을 입거나 벗는 행동이 자연스러우면서도 도움을 청하는 경우가 많습니 다 음식에 배식되었을 때 냄새 맡는 행동을 보이며 먹기 싫은 음식에 대해서는 전혀 시도하지 않고 호기심에 먹은 음식이 입에 맞지 않으면 뱉어내거나 입에 오랫동안 물고 있다가 뱉어내는 경향이 있습니다.			
신체운동	감각과 신체 인식하기	시각, 청각, 촉각, 후각, 미각으로 자극을 느끼며 반응한다.	√	
		감각기관으로 주변 환경을 탐색한다.	√	
		주요 신체 부분의 움직임을 탐색한다.	√	
	신체조절과 기본운동하기	안정되게 서 있기 등의 자세를 시도한다.	√	
		누웠다 앉기 등 몸의 움직임을 조절한다.	√	
		눈과 손을 활용하여 소근육을 활용해 본다.	√	
		걸기 등 어족운동을 시도한다.	√	
		서있기, 앉기, 등의 제자리 운동을 시도한다.	√	
	신체활동에 참여하기	몸의 움직임을 다양하게 시도한다.	√	
		규칙적으로 바깥에서 신체활동을 한다.	√	
	간단한 기구를 이용하여 신체활동을 시도한다.	√		
평가	기구를 이용하여 신체활동을 할 수 있으며 신체의 각부분의 대응을 알고 움직임을 조절할 수 있습니다. 다양한 놀이기구를 사용하며 즐거움을 알고, 특히 흥분과 타는 것을 좋아하여 대근육을 촉진하는 활동을 많이 하는 편입니다. 반면 눈과 손의 협응력을 요구하는 소근육 거르는 활동에 있어서는 크게 관심을 보이지 않아 교사의 적극적인 권유와 지속적인 지도가 이루어지고 있습니다.			

탐지 가능한 행동 특성 정리

0세

- 손뼉을 친다.
- 혼자 설 수 있다.
- 아무렇게나 물건을 던진다.
- 두발로 걷기 시작 한다.
- 물건을 입속에 넣을 수 있다.
- 간단한 악기를 두드릴 수 있다.

1세

- 혼자 걷는다.
- 낙서를 한다.
- 뒷걸음질을 할 수 있다.
- 공을 굴리거나 던질 수 있다.
- 모양, 색을 구분하여 탑을 쌓는다.
- 종이를 손으로 찢는다.

행동 영역

신체운동영역

- 감각과 신체 인식하기
- 신체조절과 기본운동하기

기본생활영역

- 건강하게 생활하기

* 출처: 어린이집 제 4차 표준보육과정

3. 테이터 구축¹⁾ 행동 선정

01 기본생활

[건강하게 생활하기]

- 스스로 컵을 잡고 마신다



02 신체운동

[신체조절과 기본운동하기]

- 손뼉을 친다



[감각과 신체 인식하기]

- 모양, 색을 구분한다



3. 데이터 구축²⁾ 데이터 수집



Kinetic-600

+



Youtube

Sipping cup



Clapping



kaggle

+




Youtube

Stacking Rings




3. 데이터 구축³⁾ 데이터 전처리



4. 데이터 모델링¹⁾ 사용 모델 소개


ViViT

이미지 분류에 특화된 Vision Transformer(ViT)를 Video data에 적용





* Transformer

: 순차 데이터 내의 관계를 추적해 맥락과 의미를 학습하는 신경망으로 비디오 시퀀스에서 프레임 간의 관계를 잡아내고 의미를 파악하는 것이 필요한 행동 인식 기술에 적합



4. 데이터 모델링 2) Tubelet & Positional Embedding



Tubelet Embedding



- Input Volume으로부터 Spatio-Temporal Tubes 추출
- d차원으로 Linear Projection 실시(ViT의 Embedding 방식을 3D로 확장한 것과 동일)

$$t \times h \times w, n_t = \frac{T}{t}, n_h = \frac{H}{h}, n_w = \frac{W}{w}$$

- 각각의 Temporal, Height, Width 차원으로부터 Token 추출

4. 데이터 모델링³⁾ Transformer Encoder : Spatio-Temporal Attention


행동에서 다른 부분들에 비해 특정 부분이 더 중요하게 판단하는 것 (Spatial)



아이의 얼굴 < 아이의 손


(중요도)

모든 프레임 중에 어떤 프레임이 더 중요하다고 판단하는 것 (Temporal)



고리를 찾는 행동 < 고리를 쌓는 행동

4. 데이터 모델링 4) MLP Multi-Head Attention



- 각 Head가 Input Sequence의 서로 다른 부분에 Attention을 줌
- Input Token 간의 더 복잡한 관계를 다룰 수 있어 Input Sequence를 더 많은 정보로 표현할 수 있음
- 다양한 유형의 종속성을 포착할 수 있어 표현력이 향상되고 Token간의 미묘한 관계를 더 잘 확인할 수 있음

5. 최종 결과

1) Parameter

```
# DATA PREPROCESS
DATA_PATH = "action"
NUM_CLASSES = 3
SPLIT_RATIOS = {"train": 0.7, "val": 0.15, "test": 0.15}
frame_rate = 15
min_frame_count = float('12')
image_size = (64, 64) # /16

BATCH_SIZE = 16
AUTO = tf.data.AUTOTUNE
INPUT_SHAPE = (12, 64, 64, 3)

# OPTIMIZER
LEARNING_RATE = 1e-4
WEIGHT_DECAY = 1e-5

# TRAINING
EPOCHS = 60

# TUBELET EMBEDDING
PATCH_SIZE = (4, 4, 4)
NUM_PATCHES = (INPUT_SHAPE[0] // PATCH_SIZE[0]) ** 2

# VIVIT ARCHITECTURE
LAYER_NORM_EPS = 1e-6
PROJECTION_DIM = 128
NUM_HEADS = 8
NUM_LAYERS = 8
```

train optimizer의 학습률 지정 : 0.0001

가중치 감쇠 지정(과적합을 방지하기 위한 정규화 기법) : 0.00001

반복학습 : 60

patch image size는 4x4x4

패치 수 계산 : $\{(28 \times 28 \times 28) // (8 \times 8 \times 8) = 3\} ** 2 = 9$



**nomalizaion layer에서 사용되는 epsilon 값 지정
<- 0으로 나누는 것을 피하기 위함**

각 패치는 128차원 벡터로 임베딩

multi head-attention에서 각 어텐션 헤드의 개수를 지정 : 8개

transformer 레이어 개수 지정 : 8개

5. 최종 결과 2) 모델 성능



Epoch은 **20**을 넘어간 뒤 성능 차이가 크게 없었고 Batch Size는 **16**일 때 가장 효율적이었음
Patch Size는 Image size를 고려해 기존 연구를 참고하여 **4x4x4**로 하였음

5. 최종 결과 2) 모델 성능

```
[12] Epoch 49/60
5/5 [=====] - 2s 461ms/step - loss: 0.8377 - accuracy: 0.6351 - top-5-accuracy: 1.0000 - val_loss: 0.7253 - val_accuracy: 0.7059
Epoch 50/60
5/5 [=====] - 2s 465ms/step - loss: 0.7438 - accuracy: 0.6892 - top-5-accuracy: 1.0000 - val_loss: 0.7507 - val_accuracy: 0.5882
Epoch 51/60
5/5 [=====] - 2s 418ms/step - loss: 0.7581 - accuracy: 0.6757 - top-5-accuracy: 1.0000 - val_loss: 0.6850 - val_accuracy: 0.7059
Epoch 52/60
5/5 [=====] - 2s 414ms/step - loss: 0.7128 - accuracy: 0.6622 - top-5-accuracy: 1.0000 - val_loss: 0.7341 - val_accuracy: 0.6471
Epoch 53/60
5/5 [=====] - 2s 455ms/step - loss: 0.7873 - accuracy: 0.6351 - top-5-accuracy: 1.0000 - val_loss: 0.6957 - val_accuracy: 0.6471
Epoch 54/60
5/5 [=====] - 2s 453ms/step - loss: 0.7084 - accuracy: 0.7297 - top-5-accuracy: 1.0000 - val_loss: 0.7566 - val_accuracy: 0.6471
Epoch 55/60
5/5 [=====] - 2s 423ms/step - loss: 0.7680 - accuracy: 0.6351 - top-5-accuracy: 1.0000 - val_loss: 0.6684 - val_accuracy: 0.7059
Epoch 56/60
5/5 [=====] - 2s 464ms/step - loss: 0.7511 - accuracy: 0.6757 - top-5-accuracy: 1.0000 - val_loss: 0.6682 - val_accuracy: 0.7059
Epoch 57/60
5/5 [=====] - 2s 454ms/step - loss: 0.7254 - accuracy: 0.6892 - top-5-accuracy: 1.0000 - val_loss: 0.6016 - val_accuracy: 0.7647
Epoch 58/60
5/5 [=====] - 2s 412ms/step - loss: 0.6801 - accuracy: 0.7027 - top-5-accuracy: 1.0000 - val_loss: 0.7062 - val_accuracy: 0.7059
Epoch 59/60
5/5 [=====] - 2s 450ms/step - loss: 0.6727 - accuracy: 0.7297 - top-5-accuracy: 1.0000 - val_loss: 0.5552 - val_accuracy: 0.7059
Epoch 60/60
5/5 [=====] - 2s 413ms/step - loss: 0.6541 - accuracy: 0.7027 - top-5-accuracy: 1.0000 - val_loss: 0.6489 - val_accuracy: 0.6471
1/1 [=====] - 0s 169ms/step - loss: 0.5416 - accuracy: 0.8667 - top-5-accuracy: 1.0000
Test accuracy: 86.67%
Test top 5 accuracy: 100.0%
```


86.7% Accuracy를 얻을 수 있었음

5. 최종 결과 3) test dataset 예측 결과

✓
4초

- ▶ 1/1 [=====] - 0s 55ms/step
- ▶ 1/1 [=====] - 0s 59ms/step
- 📄 1/1 [=====] - 0s 77ms/step
- ▶ 1/1 [=====] - 0s 89ms/step
- ▶ 1/1 [=====] - 0s 119ms/step
- ▶ 1/1 [=====] - 0s 44ms/step
- ▶ 1/1 [=====] - 0s 50ms/step
- ▶ 1/1 [=====] - 0s 44ms/step
- ▶ 1/1 [=====] - 0s 43ms/step
- ▶ 1/1 [=====] - 0s 41ms/step

'T: Clapping | P: Clapping'



'T: Clapping | P: Clapping'




'T: Clapping | P: Clapping'



'T: Clapping | P: Clapping'



'T: Clapping | P: Clapping'



'T: Sipping | P: Stacking_Rings'



'T: Sipping | P: Sipping'



'T: Sipping | P: Clapping'



'T: Stacking_Rings | P:
Stacking_Rings'



'T: Stacking_Rings | P:
Stacking_Rings'



6. 서비스 기획 구상 1) 발달 특성 체크 리스트 작성

어린이집 운영

아동 출석 관리

프로그램

월간 놀이 계획

일지 작성

관찰지 작성

발달 행동 탐지 조회


행동 검색

날짜 검색

알림사항

반영 전체 행동 분류 영역 전체 행동명 전체 아동명 검색

행동 분류	분류 영역	보기
stacking rings	신체 운동 영역	▶
clapping	신체 운동 영역	▶
⋮	⋮	⋮



✓ 옵션 선택
날짜 및 아동별 행동 검색

✓ 원본 영상 저장
행동 영상 열람 가능

✓ 행동별 기록
발달 행동별 자동 분류

6. 서비스 기획 구상 2) 우리 아이 행동 알리미

탐지된 행동의 캡처 image와 함께 행동 설명 문장 출력



✓ 날짜 및 시간 정보

이미지 저장 시간 등록

✓ 활동 태그

행동 영역 검색 가능

✓ 활동 설명 출력

'고리 쌓기 놀이를 했어요.'
'놀이 중에 링을 쌓았어요.'
'물건 많이 쌓은 링 쌓기 놀이를 했어요.'
'작은 링으로 쌓은 링 쌓기 놀이를 했어요.'
'높은 탑을 쌓은 놀이를 했어요.'
'재미있는 고리 쌓기 놀이를 했어요.'

'모양과 색이 다양한 링 쌓기 놀이를 했어요.'

Stacking Ring 0.812



6. 서비스 기획 3) 기대효과 및 발전 방향

기대 효과



- 더 정확한 발달 체크리스트를 만들 수 있음
- 놓쳐왔던 사소한 행동들까지 체크할 수 있음
- 발달지연을 조기에 발견할 수 있음
- 부모들에게 아이의 발달과 관련된 더 많은 정보 제공이 가능함

6. 서비스 기획 3) 기대효과 및 발전 방향

발전 방향



- 다중 객체 탐지를 통해 여러 아이의 행동을 탐지할 수 있도록
- 행동을 할 때 소지하고 있는 물건을 탐지해 더 자세한 동작 구분 가능 및 구체적인 알림장 생성
- 자연어 모델과 결합해 행동 탐지 후 다양한 문장 생성할 수 있도록
- 유치원, 어린이집 뿐만 아니라 가정에서도 사용할 수 있도록

참고문헌

- 보건복지부 「제4차 어린이집 표준보육과정 고시」
- 키드키즈 놀이교육계획안 및 아동 관찰지 예문
- 키드키즈 연령별 발달행동 체크리스트 - 0~1세
- Video Transformer Network [ICCV2021]
- An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale [ICLR 2021]
- ViViT : A Video Vision Transformer [ICCV2021]
- MobileViT: Light-weight, General-purpose, and Mobile-friendly Vision Transformer [ICLR 2022]
- <https://github.com/google-research/scenic>
- 딥러닝 기반 행동 인식을 위한 비디오 처리기술 연구 동향
- Learning Spatiotemporal Features with 3D Convolutional Networks [ICCV2015]
- https://huggingface.co/docs/transformers/main/model_doc/mobilevitv2
- Is Space-Time Attention All You Need for Video Understanding? [ICML2021]
- MViTv2: Improved Multiscale Vision Transformers for Classification and Detection [CVPR2022]
- https://www.tensorflow.org/hub/tutorials/action_recognition_with_tf_hub?hl=ko



감사합니다